VISION PAR ORDINATEUR

Calculs et mesures sur une image numérique

Support de cours – Master IA

Plan du support

Séance 1
Calculs numériques, statistiques et comparaison d'images

Séance 2
Gradient, mesures géométriques et caractéristiques d'objets

Pr. Issam QAFFOU

Département d'Informatique — Faculté des Sciences Semlalia (FSSM)
Université Cadi Ayyad, Marrakech

Table des matières

1 Séance 1 — Calculs numériques, statistiques et comparaison **3**

Objectifs de la séance . . . 3

1.1 Une image comme objet mathématique . . . 3

1.1.1 Représentation matricielle . . . 3

1.1.2 Exemple de représentation . . . 4

1.2 Statistiques globales sur une image . . . 5

1.2.1 Moyenne des intensités . . . 5

1.2.2 Variance et écart-type . . . 5

1.2.3 Histogramme . . . 6

1.2.4 Entropie . . . 7

1.3 Opérations entre images . . . 8

1.3.1 Opérations pixel à pixel . . . 8

1.3.2 Comparaison de deux images : MAE et MSE . . . 8

1.3.3 PSNR . . . 9

1.4 Calculs locaux et convolution . . . 10

1.4.1 Calculs sur un voisinage . . . 10

1.4.2 Convolution 2D . . . 10

1.5 Travaux pratiques et exercices . . . 12

Bilan de la séance 1 . . . 13

2 Séance 2 — Gradient, mesures géométriques et caractéristiques **14**

Objectifs de la séance . . . 14

2.1 Pourquoi mesurer un objet ? . . . 14

2.2 Gradient d'une image . . . 14

2.2.1 Dérivées discrètes . . . 14

2.2.2 Magnitude et direction . . . 15

2.3 De l'image binaire aux mesures géométriques . . . 16

2.3.1 Image binaire . . . 16

2.3.2 Aire . . . 16

2.3.3 Centroïde . . . 16

2.3.4 Périmètre . . . 17

2.3.5 Bounding box . . . 18

2.3.6 Circularité et autres descripteurs de forme . . . 18

2.4 Du pixel au vecteur de caractéristiques . . . 20

2.5 Travaux pratiques et exercices . . . 20

Bilan général des deux séances 21

Annexe – Formulaire récapitulatif **22**

Chapitre 1

Séance 1 — Calculs numériques, statistiques et comparaison

Objectifs de la séance

À l'issue de cette séance, l'étudiant doit être capable de :

- représenter une image comme une matrice de nombres ;
- calculer la moyenne, la variance et l'écart-type des intensités ;
- construire et interpréter un histogramme ;
- calculer l'entropie d'une image ;
- réaliser des opérations pixel à pixel ;
- comparer deux images à l'aide du MAE, du MSE et du PSNR ;
- comprendre les calculs locaux et la convolution.

1.1 Une image comme objet mathématique

1.1.1 Représentation matricielle

Une image numérique n'est, du point de vue du calcul, rien d'autre qu'un tableau de nombres. C'est cette observation, en apparence triviale, qui permet d'appliquer à l'image tout l'arsenal des outils mathématiques : statistiques, algèbre linéaire, traitement du signal, apprentissage automatique.

Définition — Image en niveaux de gris

Une image en niveaux de gris est une fonction discrète

$$I : \{0, \dots, W-1\} \times \{0, \dots, H-1\} \longrightarrow [0, 255]$$

où W et H sont respectivement la largeur et la hauteur de l'image (en pixels), et $I(x, y)$ désigne l'intensité (le niveau de gris) du pixel situé à la colonne x et à la ligne y, pour une image codée sur 8 bits.

Par convention, $I(x, y) = 0$ correspond au noir et $I(x, y) = 255$ au blanc ; toutes les valeurs intermédiaires correspondent à des nuances de gris. Chaque pixel possède donc une valeur numérique unique, et l'image entière peut être vue comme une matrice $H \times W$.

Remarque — Profondeur de codage

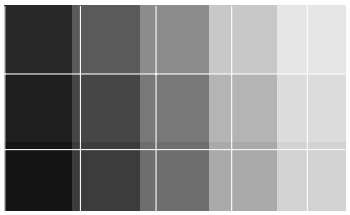
La borne $255 = 2^8 - 1$ correspond à un codage sur 8 bits par pixel (le cas le plus courant). Certaines images médicales ou scientifiques utilisent un codage sur 16 bits ($[0, 65535]$) ou même en nombres flottants (imagerie HDR). Le raisonnement mathématique présenté ici reste valable, seule la borne MAX change.

Pour une image couleur, on associe à chaque pixel un triplet d'intensités :

$$I(x, y) = [R(x, y),\, G(x, y),\, B(x, y)]$$

On peut voir une image couleur comme trois matrices superposées (les canaux rouge, vert et bleu), chacune de même dimension $H \times W$. La plupart des calculs présentés dans ce cours (moyenne, histogramme, gradient...) s'appliquent d'abord canal par canal, ou après conversion en niveaux de gris via une combinaison pondérée telle que

$$I_{\text{gris}}(x, y) = 0.299\, R(x, y) + 0.587\, G(x, y) + 0.114\, B(x, y).$$



$I(x, y)$ – niveaux de gris



Image couleur – 3 canaux superposés

FIGURE 1.1 – Une image en niveaux de gris est une matrice de scalaires ; une image couleur, trois matrices superposées.

1.1.2 Exemple de représentation

Exemple — Extrait 4×4

Considérons l'extrait suivant d'une image en niveaux de gris :

$$I = \begin{pmatrix} 12 & 15 & 20 & 25 \\ 10 & 18 & 22 & 30 \\ 8 & 14 & 25 & 35 \\ 5 & 10 & 20 & 40 \end{pmatrix}$$

Chaque case est un pixel, chaque nombre son intensité. Les valeurs faibles (proches de 0) correspondent à des zones sombres ; les valeurs plus élevées à des zones plus claires. On observe ici un dégradé assez régulier, croissant du coin supérieur gauche vers le coin inférieur droit.

Une fois l'image ramenée à une matrice de nombres, on peut lui appliquer des outils mathématiques standards : moyenne, variance, transformée de Fourier, convolution, etc. C'est le fil conducteur de toute cette séance.

1.2 Statistiques globales sur une image

1.2.1 Moyenne des intensités

Définition — Moyenne

Pour une image de N pixels d'intensités $I_1, \ldots, I_N$ (indexation à plat de la matrice), la moyenne est

$$\mu = \frac{1}{N} \sum_{i=1}^{N} I_i.$$

La moyenne μ indique la *luminosité moyenne* de l'image :

- une moyenne faible traduit une image globalement sombre ;
- une moyenne élevée traduit une image globalement claire.

Exemple — Calcul de la moyenne

Pour la ligne de pixels $[10, 20, 30, 40]$:

$$\mu = \frac{10 + 20 + 30 + 40}{4} = \frac{100}{4} = 25.$$

Remarque — Limite de la moyenne seule

Deux images très différentes peuvent avoir exactement la même moyenne (par exemple une image uniforme à 128 et une image en damier noir/blanc alternant 0 et 255). La moyenne seule ne dit donc rien sur le *contraste* ni sur la *répartition spatiale* des intensités : il faut la compléter par la variance et l'histogramme.

1.2.2 Variance et écart-type

Définition — Variance et écart-type

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^{N} (I_i - \mu)^2 \qquad \sigma = \sqrt{\sigma^2}$$

La variance σ^2 mesure la *dispersion* des intensités autour de la moyenne μ ; l'écart-type σ, exprimé dans la même unité que les intensités (niveaux de gris), est plus directement interprétable. Ces deux grandeurs sont notamment utilisées pour caractériser le *contraste* d'une image : un σ faible indique une image plate (peu de contraste), un σ élevé une image riche en contrastes.

Exemple — Calcul de la variance

Reprenons $[10, 20, 30, 40]$, de moyenne $\mu = 25$.

$$\sigma^2 = \frac{(10-25)^2 + (20-25)^2 + (30-25)^2 + (40-25)^2}{4} = \frac{225 + 25 + 25 + 225}{4} = \frac{500}{4} = 125$$

$$\sigma = \sqrt{125} \approx 11.18$$

1.2.3 Histogramme

Définition — Histogramme

L'histogramme d'une image 8 bits est la fonction

$$H(k) = \#\{(x, y) \mid I(x, y) = k\}, \qquad k \in \{0, \ldots, 255\}$$

c'est-à-dire le nombre de pixels dont l'intensité vaut exactement k. On note parfois l'histogramme normalisé (une distribution de probabilité empirique)

$$p(k) = \frac{H(k)}{N}, \qquad \sum_{k=0}^{255} p(k) = 1.$$

L'histogramme décrit la *distribution* des niveaux de gris de l'image : contrairement à μ et σ qui résument l'image en deux nombres, l'histogramme conserve l'information complète sur la répartition des intensités (au prix de la localisation spatiale, qui est perdue).

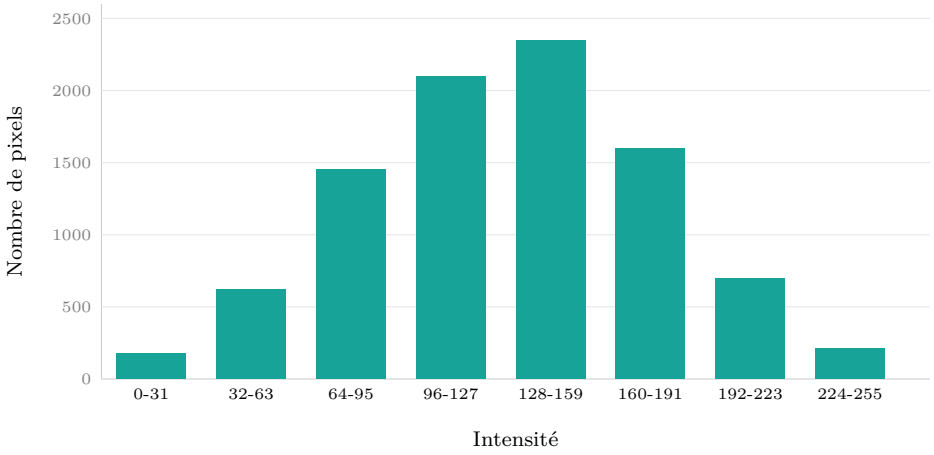


FIGURE 1.2 – Exemple d'histogramme (illustration).

Interprétation de l'histogramme

Forme observée	Interprétation
Concentré à gauche	Image sombre
Concentré à droite	Image claire
Distribution étroite	Faible diversité d'intensités (peu de contraste)
Distribution étalée	Diversité d'intensités importante (fort contraste)
Plusieurs pics (multimodal)	Plusieurs populations de pixels possibles (par ex. objet + fond)

Cette dernière observation est à la base des méthodes de *seuillage par histogramme* (comme le seuillage d'Otsu), qui cherchent la vallée entre deux pics pour séparer automatiquement un objet de son arrière-plan.

1.2.4 Entropie

Définition — Entropie de Shannon d'une image

$$H = -\sum_{k=0}^{255} p(k)\,\log_2 p(k), \qquad p(k) = \frac{H(k)}{N}$$

(par convention, $0 \log_2 0 = 0$).

L'entropie mesure la *diversité* (le désordre) de la distribution des intensités, en bits. Une distribution très concentrée (image quasi uniforme) possède une entropie faible, car il y a peu d'incertitude sur la valeur d'un pixel tiré au hasard ; une distribution étalée sur de nombreux niveaux possède une entropie plus élevée.

Exemple — Cas extrêmes

— Image parfaitement uniforme (tous les pixels valent k_0) : $p(k_0) = 1$, tous les autres $p(k) = 0$, donc $H = -1 \cdot \log_2 1 = 0$ bit.

— Image dont les 256 niveaux sont équiprobables : $p(k) = 1/256$ pour tout k, donc

$$H = -\sum_{k=0}^{255} \frac{1}{256} \log_2 \frac{1}{256} = \log_2 256 = 8 \text{ bits},$$

soit le maximum théorique atteignable pour un codage 8 bits.

Remarque — Lien avec la compression

L'entropie donne une borne inférieure théorique (au sens de Shannon) sur le nombre moyen de bits nécessaires pour coder chaque pixel sans perte : une image de forte entropie est difficile à compresser, une image de faible entropie se compresse très bien.

1.3 Opérations entre images

1.3.1 Opérations pixel à pixel

Définition — Opérations arithmétiques pixel à pixel

Soient A et B deux images de même taille. On définit, pour chaque pixel (x, y) :

$$\begin{aligned} \text{Addition} &: C(x,y) = A(x,y) + B(x,y) \\ \text{Soustraction} &: C(x,y) = A(x,y) - B(x,y) \\ \text{Différence absolue} &: D(x,y) = |A(x,y) - B(x,y)| \end{aligned}$$



FIGURE 1.3 – Deux images de même taille combinées pixel par pixel.

Ces opérations trouvent des applications directes en comparaison d'images, en détection de changement (différence entre deux images d'une même scène à des instants différents), et en détection de mouvement (différence entre deux images vidéo consécutives). Une valeur de $D(x, y)$ proche de 0 signale une zone inchangée ; une valeur élevée signale un changement.

1.3.2 Comparaison de deux images : MAE et MSE

Définition — Erreur moyenne absolue et erreur quadratique moyenne

Pour deux images I et J de N pixels :

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N} |I_i - J_i| \qquad \text{MSE} = \frac{1}{N}\sum_{i=1}^{N} (I_i - J_i)^2$$

— Le **MAE** traite chaque écart proportionnellement à sa taille : une erreur de 20 niveaux de gris compte deux fois plus qu'une erreur de 10.

— Le **MSE**, à cause du carré, *pénalise davantage les grandes erreurs* : une erreur de 20 compte quatre fois plus qu'une erreur de 10.

Dans les deux cas, des valeurs faibles indiquent une plus grande proximité entre les deux images ; une valeur nulle signifie que les deux images sont identiques.

Exemple — MAE et MSE

Soit $I = [10, 20, 30, 40]$ et $J = [12, 18, 33, 35]$. Les écarts sont $[-2, 2, -3, 5]$.

$$\text{MAE} = \frac{2+2+3+5}{4} = \frac{12}{4} = 3$$

$$\text{MSE} = \frac{4+4+9+25}{4} = \frac{42}{4} = 10.5$$

On remarque que l'écart de 5 (le plus grand) pèse proportionnellement plus dans le MSE ($25/42 \approx 60\%$ de la somme) que dans le MAE ($5/12 \approx 42\%$).

1.3.3 PSNR

Définition — Peak Signal-to-Noise Ratio

$$\text{PSNR} = 10\,\log_{10}\left(\frac{\text{MAX}^2}{\text{MSE}}\right)$$

où MAX est la valeur maximale possible d'un pixel (MAX = 255 pour une image 8 bits). Le PSNR s'exprime en décibels (dB).

Le PSNR est très utilisé pour évaluer la fidélité d'une image reconstruite, compressée (JPEG) ou débruitée par rapport à une image de référence. Un PSNR plus élevé correspond généralement à une erreur (MSE) plus faible, donc à une meilleure fidélité.

PSNR	**Qualité perçue (repères usuels)**
< 20 dB	Qualité faible, forte dégradation visible
20–30 dB	Qualité moyenne
30–40 dB	Bonne qualité
> 40 dB	Très proche de l'image originale

TABLE 1.1 – Repères usuels d'interprétation du PSNR (indicatifs, dépendants de l'application).

Exemple — Calcul du PSNR

Avec MSE = 10.5 (exemple précédent) et MAX = 255 :

$$\text{PSNR} = 10\log_{10}\left(\frac{255^2}{10.5}\right) = 10\log_{10}(6189.3) \approx 37.9 \text{ dB}$$

Remarque — PSNR et perception humaine

Le PSNR est une mesure purement statistique, pixel à pixel : deux images peuvent avoir un PSNR élevé tout en présentant des différences visuellement gênantes (ou inversement). Des mesures perceptuelles comme le SSIM (*Structural Similarity Index*) tentent de mieux refléter le jugement humain en tenant compte de la structure locale de l'image.

1.4 Calculs locaux et convolution

1.4.1 Calculs sur un voisinage

Jusqu'ici, chaque pixel était traité indépendamment (opérations *ponctuelles*) ou l'image entière était résumée par un seul nombre (opérations *globales*). Une troisième famille d'opérations, les opérations *locales*, analyse chaque pixel en tenant compte de ses **voisins**.

Définition — Voisinage et fenêtre glissante

On appelle voisinage d'un pixel (x, y), de taille $n \times n$ (typiquement 3×3), l'ensemble des pixels

$$V(x, y) = \{I(x + i, y + j) \mid i, j \in \{-\lfloor n/2 \rfloor, \ldots, \lfloor n/2 \rfloor\}\}.$$

Une *fenêtre glissante* de taille $n \times n$ parcourt l'image position par position ; à chaque position, une statistique du voisinage (moyenne, minimum, maximum, médiane, variance locale) est calculée et affectée au pixel central de la sortie.

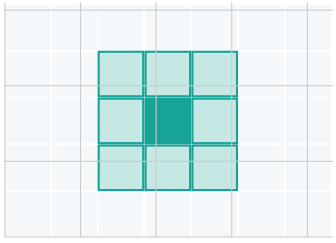


FIGURE 1.4 – Fenêtre 3×3 (en teinte claire) centrée sur le pixel courant (en foncé).

Ces opérations locales sont à la base de très nombreux filtres spatiaux : lissage (réduction du bruit), accentuation des détails, détection de contours, etc. Elles s'expriment de façon unifiée par la **convolution**.

1.4.2 Convolution 2D

Définition — Convolution discrète 2D

Soit I une image et K un noyau (*kernel*) de taille $(2a + 1) \times (2b + 1)$. La convolution de I par K est l'image

$$I'(x, y) = \sum_{i=-a}^{a} \sum_{j=-b}^{b} K(i, j)\, I(x - i,\, y - j).$$

En traitement d'image, on utilise très souvent la *corrélation croisée* (même formule, sans retournement du noyau) ; la distinction est peu visible en pratique pour des noyaux symétriques.

Concrètement : le noyau K est déplacé sur l'image, position par position ; à chaque position, on effectue une somme pondérée des pixels sous le noyau, et le résultat devient la nouvelle valeur du pixel correspondant dans l'image de sortie.

Exemple — Filtre moyenne 3×3

Le filtre moyenne (lissage) est défini par le noyau

$$K = \frac{1}{9}\begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}.$$

Appliqué à un pixel et ses 8 voisins, il remplace le pixel central par la moyenne arithmétique des 9 valeurs du voisinage – un simple cas particulier de la fenêtre glissante décrite ci-dessus.

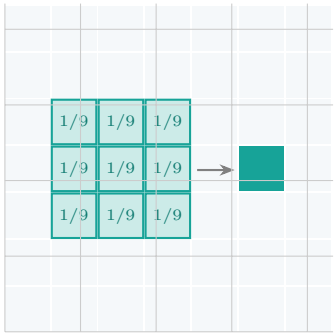


FIGURE 1.5 – Le noyau K glisse case par case sur toute l'image ; chaque position produit un pixel de sortie.

Selon les coefficients choisis pour K, la convolution permet : le **lissage** et le **flou** (coefficients positifs, somme $= 1$, type moyenne ou gaussienne), la **détection de contours** (noyaux de type Sobel, Prewitt, Laplacien, à coefficients positifs et négatifs), ou l'**accentuation** des détails (*sharpening*, en renforçant le centre par rapport aux voisins). Le gradient et les filtres de contours étudiés en séance 2 sont eux-mêmes des convolutions particulières.

Remarque — Effets de bord

Au bord de l'image, le noyau déborde de la matrice : il faut choisir une convention (rembourrage par des zéros, *padding* en dupliquant le bord, *padding* en miroir, ou réduction de la taille de l'image de sortie). Ce choix peut avoir un impact visible sur les pixels de bordure.

1.5 Travaux pratiques et exercices

TP 1 — Calculs numériques

1. Charger une image en niveaux de gris.
2. Calculer min, max, moyenne, variance et écart-type.
3. Afficher et interpréter son histogramme.
4. Calculer son entropie.
5. Comparer deux images avec MAE et MSE.
6. Calculer le PSNR.
7. Appliquer un filtre moyenne 3×3 et comparer les résultats (visuellement et via σ).

Exercice 1.1

Soit l'image 4×4 de la section 1.2. Calculer sa moyenne μ et sa variance σ^2.

La somme des 16 valeurs est $12+15+20+25+10+18+22+30+8+14+25+35+5+10+20+40 = 309$, donc

$$\mu = \frac{309}{16} \approx 19.31.$$

La variance se calcule ensuite en sommant $(I_i - \mu)^2$ pour les 16 valeurs puis en divisant par 16 ; on obtient $\sigma^2 \approx 94.5$ et $\sigma \approx 9.72$ (valeurs arrondies).

Exercice 1.2

Deux images 8×8 identiques sauf sur un carré 2×2 où l'écart vaut $+50$ sur les 4 pixels concernés (tous les autres écarts sont nuls). Calculer le MAE et le MSE ($N = 64$).

$$\mathrm{MAE} = \frac{4 \times 50}{64} = \frac{200}{64} \approx 3.13 \qquad \mathrm{MSE} = \frac{4 \times 50^2}{64} = \frac{10000}{64} \approx 156.25$$

Le MSE amplifie fortement l'effet d'une erreur localisée mais importante, alors que le MAE la « dilue » sur l'ensemble de l'image.

Exercice 1.3

Une image binaire ($p(0) = p(255) = 0.5$, tous les autres $p(k) = 0$) : quelle est son entropie ? Comparer à une image uniforme.

$$H = -\Big(0.5 \log_2 0.5 + 0.5 \log_2 0.5\Big) = -\log_2 0.5 = 1 \text{ bit.}$$

C'est strictement supérieur à l'entropie nulle d'une image uniforme (un seul niveau), mais bien inférieur au maximum de 8 bits atteint lorsque les 256 niveaux sont équiprobables : ici, la diversité de l'image se limite à deux valeurs possibles.

Bilan de la séance 1

— Une image est une matrice de valeurs numériques.

— Les statistiques globales (μ, σ, entropie) décrivent l'image en quelques nombres.

— L'histogramme décrit la distribution complète des intensités.

— Les opérations pixel à pixel permettent de comparer ou combiner des images.

— Les calculs locaux exploitent le voisinage ; la convolution les généralise.

Chapitre 2

Séance 2 — Gradient, mesures géométriques et caractéristiques

Objectifs de la séance

À l'issue de cette séance, l'étudiant doit être capable de :

- comprendre le gradient d'une image et le calculer (magnitude, direction) ;
- mesurer les propriétés géométriques d'un objet segmenté : aire, périmètre, centroïde ;
- déterminer une bounding box et des descripteurs de forme ;
- construire un vecteur de caractéristiques exploitable par un algorithme d'apprentissage.

2.1 Pourquoi mesurer un objet ?

Après segmentation, une image peut contenir plusieurs objets ou régions d'intérêt. L'objectif de cette séance est de transformer chaque objet en une poignée d'**informations numériques** (taille, position, forme, compacité...), afin de pouvoir ensuite classifier ou regrouper les objets automatiquement.



2.2 Gradient d'une image

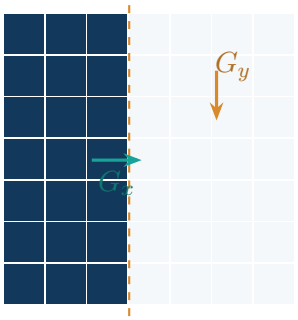
2.2.1 Dérivées discrètes

Définition — Gradient

Le gradient d'une image mesure les *variations locales d'intensité*. Il est défini, par analogie avec le gradient d'une fonction continue, à partir des dérivées partielles discrètes

$$G_x = \frac{\partial I}{\partial x} \approx I(x+1, y) - I(x-1, y), \qquad G_y = \frac{\partial I}{\partial y} \approx I(x, y+1) - I(x, y-1).$$

Une forte variation d'intensité (par exemple à la frontière entre un objet clair et un fond sombre) produit une forte réponse du gradient ; c'est pourquoi les **contours** d'une image sont, presque par définition, des zones de fort gradient.



Transition sombre → clair : forte réponse au gradient

2.2.2 Magnitude et direction

Définition — Magnitude et direction du gradient

$$G = \sqrt{G_x^2 + G_y^2} \qquad \theta = \arctan\left(\frac{G_y}{G_x}\right)$$

La magnitude G indique l'*importance* de la variation locale (elle est utilisée pour détecter la présence d'un contour, souvent après seuillage) ; la direction θ indique l'*orientation* de ce contour (perpendiculaire à la direction du gradient).

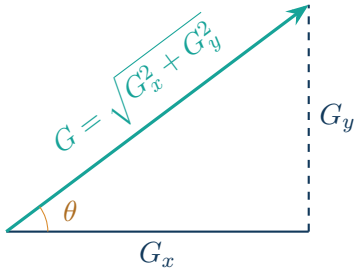


FIGURE 2.1 – Composition vectorielle du gradient.

Exemple — Calcul numérique

Si $G_x = 30$ et $G_y = 40$ en un pixel donné :

$$G = \sqrt{30^2 + 40^2} = \sqrt{900 + 1600} = \sqrt{2500} = 50, \qquad \theta = \arctan\left(\frac{40}{30}\right) \approx 53.1°.$$

Remarque — Opérateurs usuels

En pratique, G_x et G_y ne sont pas calculés par simple différence de deux pixels (trop sensible au bruit), mais par convolution avec un noyau qui combine dérivation et lissage. Le plus connu est l'opérateur de **Sobel** :

$$K_x = \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}, \qquad K_y = \begin{pmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}.$$

D'autres opérateurs classiques (Prewitt, Laplacien, détecteur de Canny) reposent sur le même principe avec des variantes de pondération ou d'ordre de dérivation.

2.3 De l'image binaire aux mesures géométriques

2.3.1 Image binaire

Définition — Image binaire

Après seuillage ou segmentation, une image binaire vérifie $I(x, y) \in \{0, 1\}$, où 0 code l'arrière-plan et 1 code l'objet (ou une région d'intérêt). Cette représentation, beaucoup plus simple qu'une image en niveaux de gris, facilite considérablement les mesures géométriques : on peut analyser séparément chaque région connexe (chaque *composante connexe*) de l'image.

Tout au long de cette section, nous utilisons le même objet binaire de référence (grille 10×8), reconstruit ci-dessous, pour illustrer successivement l'aire, le centroïde, le périmètre, la bounding box et la circularité – un même exemple suivi de bout en bout.

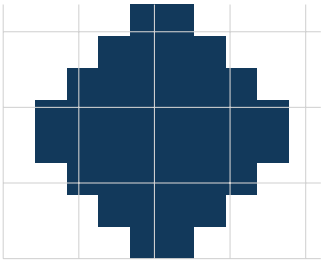


FIGURE 2.2 – Objet binaire de référence utilisé dans toute la section 3.2.

2.3.2 Aire

Définition — Aire

Pour un objet binaire, l'aire est simplement

$$A = \sum_{x,y} I(x, y),$$

c'est-à-dire le nombre de pixels appartenant à l'objet. Si la résolution physique de l'image est connue (par exemple en mm/pixel), l'aire peut être convertie en unités réelles.

L'aire est la première mesure, la plus simple, de la taille d'un objet.

Exemple — Aire de l'objet de référence

En comptant les pixels de la figure 2.2 ligne par ligne : $2 + 4 + 6 + 8 + 8 + 6 + 4 + 2 = 40$. Donc $A = 40$ pixels.

2.3.3 Centroïde

Définition — Centroïde

$$x_c = \frac{1}{A} \sum_{x,y} x\, I(x, y), \qquad y_c = \frac{1}{A} \sum_{x,y} y\, I(x, y).$$

Le centroïde (x_c, y_c) donne la position du *centre géométrique* (le barycentre) de l'objet ; il est très utile pour localiser un objet en une seule coordonnée, ou pour suivre son déplacement d'une image

à l'autre (suivi d'objets, *tracking*).

Exemple — Centroïde de l'objet de référence

Un calcul direct (somme des coordonnées x et y pondérées, divisée par $A = 40$) donne

$$x_c = 4.5, \qquad y_c = 3.5,$$

ce qui correspond bien, par symétrie, au centre de la forme.

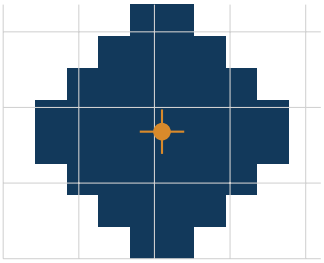


FIGURE 2.3 – Centroïde $(x_c, y_c) = (4.5, 3.5)$.

2.3.4 Périmètre

Définition — Périmètre

Le périmètre mesure la longueur du contour de l'objet. La méthode la plus simple consiste à compter les pixels de *contour* : un pixel de l'objet est un pixel de contour s'il possède au moins un voisin (parmi ses 4 voisins directs) appartenant à l'arrière-plan.

Le périmètre est souvent utilisé conjointement avec l'aire pour caractériser une forme (voir la circularité, section 3.6). Sa valeur numérique dépend fortement de la résolution de l'image et de la méthode de calcul retenue – une remarque importante que nous détaillons ci-après.

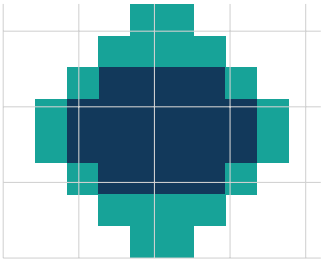


FIGURE 2.4 – Pixels de contour en surbrillance – $P \approx 20$ pixels pour l'objet de référence.

Remarque — Le périmètre par comptage de pixels sous-estime le vrai contour

Deux pixels de contour « en escalier » (diagonale) sont en réalité séparés par une distance de $\sqrt{2} \approx 1.41$, alors qu'un simple comptage de pixels de contour les compte comme des unités de longueur 1. Le périmètre « réel » (au sens du polygone qui entoure l'objet) est donc systématiquement plus grand que le nombre de pixels de contour ne le suggère. Des méthodes plus précises, comme le *codage de la chaîne de Freeman* (qui distingue déplacements horizontaux/verticaux de longueur 1 et déplacements diagonaux de longueur $\sqrt{2}$), donnent une estimation plus fidèle.

2.3.5 Bounding box

Définition — Bounding box (boîte englobante)

On recherche les coordonnées extrêmes de l'objet :

$$x_{\min},\ x_{\max},\ y_{\min},\ y_{\max},$$

puis

$$\text{Largeur} = x_{\max} - x_{\min} + 1, \qquad \text{Hauteur} = y_{\max} - y_{\min} + 1.$$

La bounding box fournit une enveloppe rectangulaire, simple et rapide à calculer, de l'objet. Elle est massivement utilisée en détection d'objets (c'est la sortie standard d'un détecteur comme YOLO ou Faster R-CNN), en localisation et en suivi.

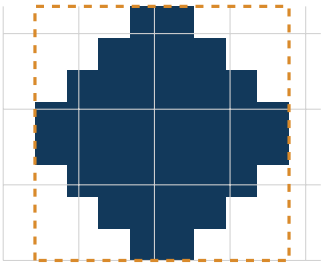


FIGURE 2.5 – Bounding box : 8×8 pixels.

2.3.6 Circularité et autres descripteurs de forme

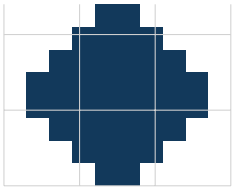
Définition — Circularité

$$C = \frac{4\pi A}{P^2}$$

où A est l'aire et P le périmètre. Une forme parfaitement circulaire donne $C = 1$ (c'est le maximum théorique pour un contour continu) ; plus la forme est allongée ou irrégulière, plus C s'éloigne de 1 (généralement vers 0).



$C \approx 0.31$ **(allongée)**



$C \approx 1.26$ **(compacte)**

Remarque — Circularité et périmètre sous-estimé

Avec $A = 40$ et $P \approx 20$ (comptage de pixels), on obtient $C = 4\pi \times 40/20^2 \approx 1.26$, une valeur *supérieure* à 1 – ce qui est en théorie impossible pour un contour continu. Ceci illustre concrètement la remarque de la section précédente : le périmètre compté en pixels est sous-estimé, ce qui gonfle artificiellement C. Une estimation de périmètre plus fidèle (chaîne de Freeman) ramènerait C à une valeur plus proche de 1, cohérente avec la forme presque circulaire de l'objet.

D'autres descripteurs de forme complètent utilement la circularité :

Descripteur	**Définition**
Aspect ratio	largeur / hauteur de la bounding box
Compacité	relation entre aire et périmètre (proche de la circularité)
Excentricité	mesure de l'allongement de l'objet
Solidité	aire / aire de l'enveloppe convexe de l'objet
Extent	aire / aire de la bounding box

2.4 Du pixel au vecteur de caractéristiques



Exemple — Vecteur de caractéristiques

Pour l'objet de référence utilisé tout au long de la section 3.2, on obtient par exemple le vecteur

$$\mathbf{f} = [\,A,\ P,\ C,\ \text{largeur},\ \text{hauteur}\,] = [40,\ 20,\ 1.26,\ 8,\ 8].$$

Ce vecteur $\mathbf{f} \in \mathbb{R}^d$ constitue une représentation numérique compacte de l'objet, directement exploitable par des algorithmes d'apprentissage automatique classiques : k plus proches voisins (KNN), machines à vecteurs de support (SVM), arbres de décision, ou méthodes de regroupement non supervisé (clustering, k-means). C'est le pont entre le traitement d'image « bas niveau » (pixels) étudié dans ce cours, et l'apprentissage automatique « haut niveau ».

Exemple de pipeline complet

1. Image d'un objet
2. Segmentation (binarisation)
3. Calcul de : aire, périmètre, circularité, aspect ratio
4. Assemblage du vecteur de caractéristiques
5. Classification ou regroupement des objets

2.5 Travaux pratiques et exercices

TP 2 — Mesures géométriques

1. Charger une image contenant plusieurs objets.
2. Produire une image binaire (seuillage).
3. Détecter les composantes connexes ou les contours.
4. Calculer l'aire de chaque objet.
5. Calculer périmètre et centroïde de chaque objet.
6. Calculer la bounding box de chaque objet.
7. Calculer circularité et aspect ratio.
8. Construire un tableau (une ligne par objet) de caractéristiques.

Mini-projet du TP

Construire, pour chaque objet détecté, le vecteur [aire, périmètre, circularité, largeur, hauteur]. Comparer les objets selon leur taille et leur forme ; identifier les objets les plus circulaires ; examiner si les caractéristiques permettent de distinguer deux catégories d'objets distinctes.

Exercice 2.1

Un objet occupe un rectangle plein de 6×4 pixels ($A = 24$). Calculer sa bounding box, son périmètre (comptage de pixels de contour) et sa circularité.

La bounding box est 6×4 (l'objet est déjà rectangulaire). Tous les pixels sauf ceux strictement à l'intérieur sont des pixels de contour ; un rectangle plein 6×4 n'a pas de pixel intérieur (car la hauteur, 4, ne laisse aucune ligne entièrement entourée de lignes pleines des deux côtés) : $P = 24$ (tous les pixels sont en surface). La circularité vaut

$$C = \frac{4\pi \times 24}{24^2} = \frac{4\pi}{24} \approx 0.524,$$

nettement inférieure à 1, ce qui reflète bien la forme allongée et anguleuse du rectangle par rapport à un disque.

Exercice 2.2

Deux objets ont la même aire $A = 100$. Le premier a un périmètre $P_1 = 40$, le second $P_2 = 70$. Lequel est le plus « circulaire» ? Justifier par le calcul.

$$C_1 = \frac{4\pi \times 100}{40^2} = \frac{400\pi}{1600} \approx 0.785, \qquad C_2 = \frac{4\pi \times 100}{70^2} = \frac{400\pi}{4900} \approx 0.256.$$

Le premier objet ($C_1 \approx 0.785$) est nettement plus circulaire que le second : à aire égale, un périmètre plus grand signale une forme plus irrégulière ou plus allongée.

Bilan général des deux séances

Étape	**Rôle**
Image	Point de départ : des données numériques brutes
Statistiques (μ, σ, entropie)	Description globale de l'image
Histogramme	Distribution complète des intensités
Gradient	Variations locales, détection des contours
Segmentation	Isolement des régions et des objets
Mesures géométriques	Propriétés quantitatives des objets (aire, périmètre, centroïde...)
Vecteur de caractéristiques	Représentation exploitable par l'apprentissage automatique

Transition vers la suite

Nous savons désormais calculer et mesurer une image et ses objets. L'étape suivante consiste à isoler *automatiquement* les régions intéressantes, en s'appuyant sur :

— la segmentation régionale (seuillage, croissance de régions, watershed) ;

— la morphologie mathématique (érosion, dilatation, ouverture, fermeture) ;

— l'extraction et l'analyse automatique des objets détectés ;

— la classification et la reconnaissance à partir des vecteurs de caractéristiques.

Annexe — Formulaire récapitulatif

Grandeur	**Formule**
Moyenne	$\mu = \dfrac{1}{N}\sum_i I_i$
Variance / écart-type	$\sigma^2 = \dfrac{1}{N}\sum_i (I_i - \mu)^2, \quad \sigma = \sqrt{\sigma^2}$
Histogramme	$H(k) = \#\{(x,y) : I(x,y) = k\}$
Entropie	$H = -\sum_k p(k)\log_2 p(k), \quad p(k) = H(k)/N$
MAE	$\dfrac{1}{N}\sum_i \lvert I_i - J_i\rvert$
MSE	$\dfrac{1}{N}\sum_i (I_i - J_i)^2$
PSNR	$10\log_{10}(\mathrm{MAX}^2/\mathrm{MSE})$
Convolution 2D	$I'(x,y) = \sum_{i,j} K(i,j)\, I(x-i, y-j)$
Gradient	$G_x = \partial I/\partial x,\ G_y = \partial I/\partial y$
Magnitude / direction	$G = \sqrt{G_x^2 + G_y^2},\ \theta = \arctan(G_y/G_x)$
Aire	$A = \sum I(x,y)$
Centroïde	$x_c = \frac{1}{A}\sum x I(x,y),\ y_c = \frac{1}{A}\sum y I(x,y)$
Bounding box	largeur $= x_{\max} - x_{\min} + 1$, hauteur $= y_{\max} - y_{\min} + 1$
Circularité	$C = 4\pi A / P^2$